


PESQUISA PARA A TESE DOUTORADO HORUS IMAGE SERVER v1.0

Luiz Marcio Faria de Aquino Viana, M.Sc.
E-mail: lmarcio@cos.ufrj.br
E-mail alt.: luiz.marcio.viana@globo.com
Phone: +55-21-99983-7207
DRE: 120048833
CPF: 024.723.347-10
RG: 08855128-8 IFP-RJ

Definição do Problema

PROBLEMA:

O crescente volume de dados produzidos pelas redes de sensores e equipamentos de gravação de imagens, torna difícil o processo de captura, transmissão, classificação e identificação dos dados coletados remotamente.




Motivações:

Capacidade de Processamento Remoto


CAPACIDADE DE PROCESSAMENTO REMOTO

O aumento na capacidade de processamento das unidades de monitoramento permite que sejam realizadas pré-classificações dos dados coletados por cada dispositivo, possibilitando a decisão pelo envio ou não da imagem e proporcionando uma redução em até 20x o volume de dados enviados.

Raspberry Pi 4 - Processador
Broadcom BCM2711, quad-core
Cortex-A72 (ARM v8) 64bit SoC – Clock
1.5 Ghz – Memória RAM: 4GB DDR4




Jetson Nano - Arquitetura NVIDIA
Maxwell com 128 NVIDIA CUDA cores -
Processador Quad-core ARM Cortex-A57
MPCore - 4 GB 64 -bit LPDDR4 - 16 GB
eMMC 5.1 Flash



Motivações: *Computation Storage*

COMPUTATION STORAGE:

O conceito de computation storage vem sendo amplamente estudado com a aplicação dos recursos de processamento diretamente na unidade de armazenamento e permitindo que diversos serviços suportados anteriormente no sistema operacional ou na camada da aplicação, estejam disponíveis na unidade de armazenamento, reduzindo o trabalho da CPU e proporcionando maior velocidade na transferência dos dados entre as unidades de armazenamento e memória.



Objetivo da Pesquisa


OBJETIVO DA PESQUISA:

Identificação de padrões nas imagens dos equipamentos de monitoramento e supervisão, com o objetivo de reduzir o volume de dados trafegados pela rede.

Pesquisa e implementar um mecanismo de armazenamento otimizado dos modelos de aprendizado de Redes Neurais aplicado na classificação de texturas, na detecção de mudanças, e no reconhecimento de padrões, explorando a capacidade de processamento das novas unidades de armazenamento denominadas computation storage.



Classificação de Texturas



Detecção de Mudanças

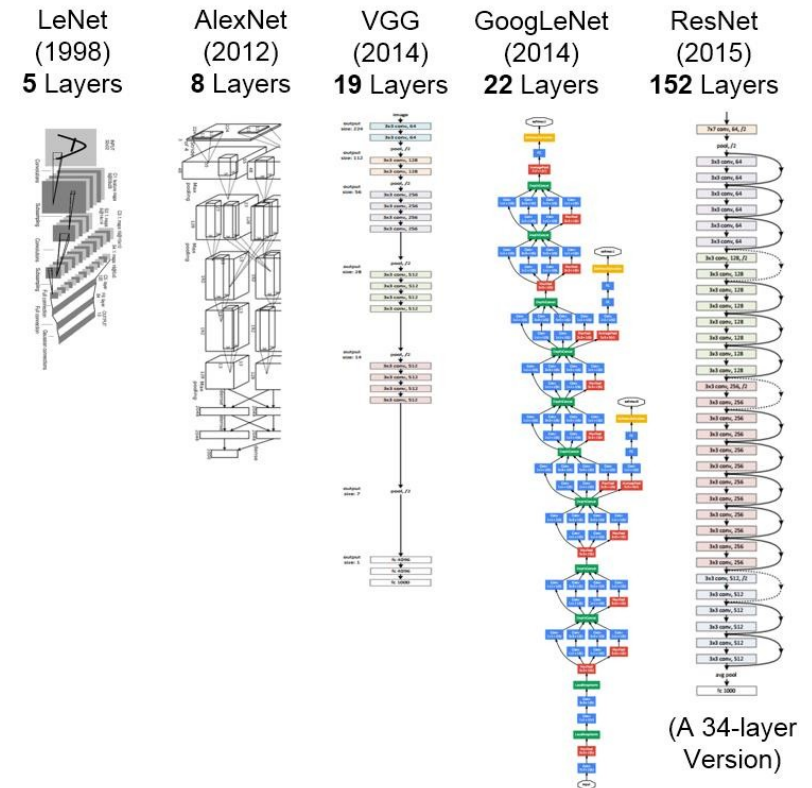




Reconhecimento de Padrões

Ferramentas e Recursos: Servidor de Imagens - HORUS

Múltiplos sensores capturando imagens, e pré-classificam os dados, enviando somente as imagens que atendem determinados critérios. Os servidores recebem os dados e armazenam em unidades CSDs, que são responsáveis por completar a classificação dos dados armazenados.

Modelo de redes neurais profundas podem ser gerado nos servidores, e em seguida, carregados nos equipamentos remotos para permitir a pré-classificação dos dados. O processamento e classificação detalhado da imagem é realizado nos servidores e armazenados nas unidades CSDs.



Conceitos Iniciais: Classificação de Texturas

CLASSIFICAÇÃO DE TEXTURAS COM REDES NEURAI

O problema de classificação de texturas em imagens é fundamental para o reconhecimento de padrões locais que se repetem em uma área maior da imagem. A identificação e classificação destes padrões locais, permite o reconhecimento de áreas da imagem que são cobertas por um mesmo padrão de textura.

Nosso objetivo é implementar um mecanismo de classificação de texturas otimizado usando Redes Neurais que permita classificar rapidamente as áreas cobertas por cada tipo de textura presente nas imagens.

Este tipo de processamento possui diversas aplicações praticas, como por exemplo, a classificação automática de diferentes tipos de solos e diferentes tipos de vegetação existentes em uma imagem de satélite.



Classificação de Texturas

Conceitos Iniciais: Detecção de Mudanças

DETECÇÃO DE MUDANÇAS COM REDES NEURAIS

O processo de detecção de mudanças em imagens possui diversas aplicações práticas, como por exemplo, o monitoramento em tempo real de áreas de segurança e a detecção automática das mudanças ocorridas na vegetação nativa de uma região ao longo do tempo. Este processo vem sendo estudado de forma intensiva usando Redes Neurais, obtendo um ganho significativo de desempenho na classificação dos dados.



Detecção de Mudanças

Conceitos Iniciais: Reconhecimento de Padrões

RECONHECIMENTO DE PADRÕES EM IMAGENS COM REDES NEURAIS

O reconhecimento de padrões em imagens é um tema que vem sendo amplamente estudado e aplicado no reconhecimento de escrita, no reconhecimento facial, e etc. A figura abaixo, apresenta um exemplo de aplicação de reconhecimento de padrões em imagens.

Neste estudo, analisaremos o uso de Redes Neurais no reconhecimento de padrões em imagens, com o objetivo de implementar de forma eficiente este modelo de Redes Neurais com a expectativa de obter uma melhora significativa no treinamento do modelo e na classificação dos dados.



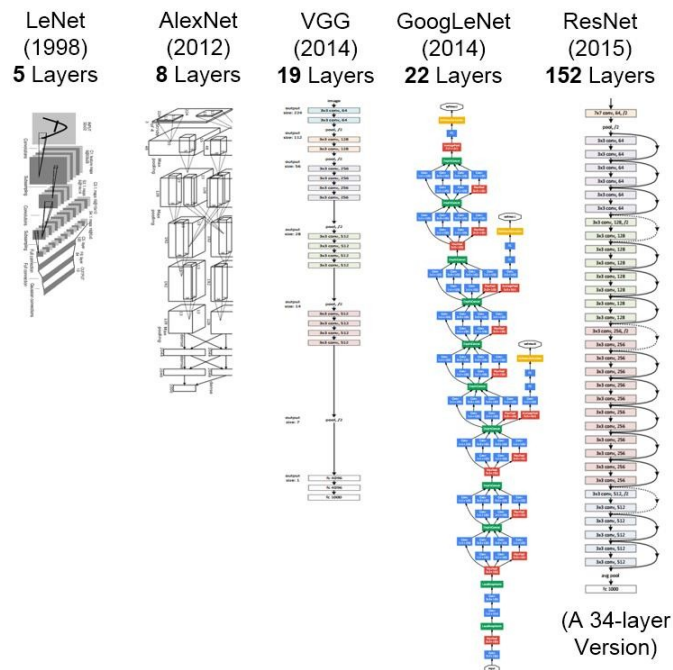
Reconhecimento de Padrões

Conceitos Iniciais: *Distributed Deep Neural Networks*

DISTRIBUTED DEEP NEURAL NETWORKS (DDNN)

O aumento na capacidade de processamento das unidades de monitoramento permite que sejam realizadas classificações nos dados coletados nos dispositivos remotos, possibilitando a decisão sobre o envio ou não da imagem.


A identificação de padrões nas imagens dos equipamentos de monitoramento e supervisão, reduz em até 20x o volume dos dados trafegados pela rede.



Raspberry Pi 4 - Processador
Broadcom BCM2711, quad-core
Cortex-A72 (ARM v8) 64bit SoC - Clock
1.5 Ghz - Memória RAM: 4GB DDR4



Jetson Nano - Arquitetura NVIDIA Maxwell
com 128 NVIDIA CUDA cores - Processador
Quad-core ARM Cortex-A57 MPCore - 4 GB 64
-bit LPDDR4 - 16 GB eMMC 5.1 Flash



Conceitos Iniciais: *Computation Storage*

COMPUTATION STORAGE

O conceito de computation storage vem sendo amplamente estudado, com a aplicação dos recursos de processamento diretamente na unidade de armazenamento, permitindo que diversos serviços suportados anteriormente no sistema operacional ou na camada da aplicação, estejam disponíveis na unidade de armazenamento, reduzindo o trabalho da CPU e proporcionando maior velocidade na transferência dos dados entre as unidades de armazenamento e memória.

Atualmente o conceito de computation storage esta sendo largamente utilizado em unidades de armazenamento para gravar os dados com segurança e com compactação, proporcionando de forma eficiente uma maior segurança e economia de espaço de armazenamento.

Outra aplicação do conceito de computation storage está relacionada com a otimização do cache das unidades de armazenamento, na otimização de consultas a bancos de dados, e na otimização de aplicações de inteligência artificial.

O nosso estudo, envolve a aplicação do conceito de computation storage no aprendizado de maquina usando Redes Neurais para armazenamento otimizado das imagens, classificação de texturas, detecção de mudança e reconhecimento de padrões em imagens, fornecendo um modelo eficiente para ser utilizado na prática.



Arquitetura dos Equipamentos: *Computation Storage*

Neste estudo serão utilizados unidades de armazenamento SSD com capacidade de processamento de dados (*computation storage*), com o objetivo de otimizar o processamento das imagens e a busca pelas informações.



Computational Storage Device

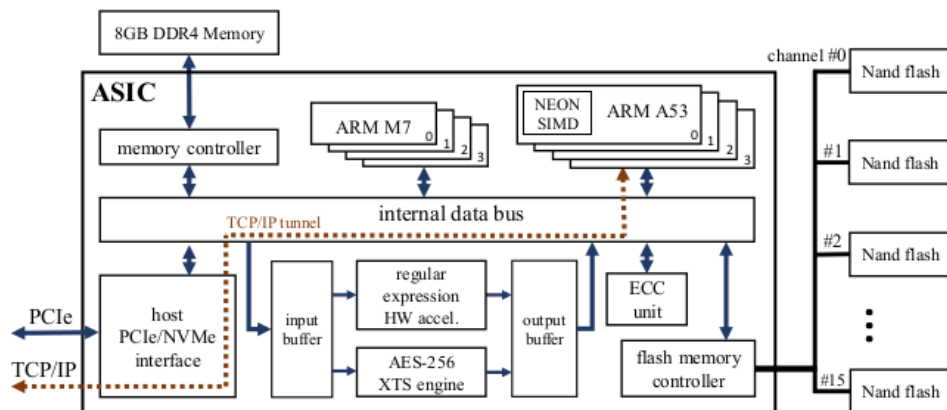
Unidade de armazenamento SSD programável, Newport CSD, desenvolvida para sobrepor as limitações das unidades de armazenamento SSD tradicionais.

Arquitetura do Hardware

A arquitetura do Newport CSD foi construída em torno de uma unidade ASIC personalizada Zynq Ultra Scale + FPGA da fabricante chinesa Xilinx.

Camada de Softwares

Linux Ubuntu 16.04.5 LTS; com TCP/IP, mas será implementado suporte para NVMe/PCIe.



Contribuições Esperadas

DESAFIOS DE TER UM GIS EM SERVIDORES COM COMPUTATION STORAGE

Grande volume de informação composta por múltiplos arquivos de dados de grandes dimensões (>400MB) que precisam ser frequentemente processados (ex: conversão do formato, reprojeção das imagens, criação de cache com diferentes níveis de precisão, comparação e identificação de mudanças, reconhecimento de padrões e etc).

GANHOS ESPERADOS COM O USO DE *COMPUTATION STORAGE*

Distribuindo o processamento nas unidades de armazenamento, obtemos maior agilidade nas tarefas de conversão de formato, reprojeção das imagens, criação de cache com diferentes níveis de precisão, comparação e identificação de mudanças e no reconhecimento de padrões.

CONTRIBUIÇÕES QUE PODEM SER OBTIDAS COM A PESQUISA

1. Contribuições em AI + IoT através da otimização dos processos de captura das imagens por sensores com câmeras;
2. Contribuição em *computation storage* com avaliação de processos de otimização do processamento e captura dos dados;
3. Contribuição para o GIS com um servidor de Banco de Dados de Imagens com grande capacidade de armazenamento e processamento de imagens;

RESULTADOS ESPERADOS

1. Maior desempenho;
2. Melhor eficiência energética;

Ambiente de Experimento Benchmark

PROBLEMA:

Em reunião com a equipe de cartografia do IBGE eles informaram que o maior problema que eles possuem está no armazenamento e processamento das imagens de 480.000 zonas censitárias existentes no Brasil.

ESTUDOS REALIZADOS:

Desta forma, a equipe do IBGE iniciou um estudo com imagens de satélites comerciais com precisão de 8 metros para serem aplicadas em futuros levantamentos de campo.

Estas imagens serão comparadas com imagens e elementos vetoriais obtidos em levantamentos de anos anteriores, para identificação mudanças e padrões nas imagens.

I. Volume grande de imagens;

II. Imagens Multispectral e True Color com resolução de 8m

- Cada cena possui 11 imagens em tons de cinza, representando as diferentes faixas de frequência e 1 imagem true color;

- Espaço estimado: 4.678 Giga Bytes (5 TB) somente as imagens deste ano;

Ambiente de Experimento Benchmark

CONSULTA E PROCESSAMENTO

O experimento inicial foi realizado com apenas 1 consulta que retorna até 4,7% dos dados totais, cerca de 190 imagens. Após a seleção das imagens, as imagens são convertidas de GeoTIFF para JPEG, reprojadas de UTM para coordenadas geográficas, e simplificadas para reduzir o tamanho a 1/4 do tamanho original.

CONFIGURAÇÃO DO SERVIDOR



Os experimentos foram realizados em um computador basico com 2 núcleos e simulando as unidades CSDs com as seguintes configurações:

- (a) Processamento em 1 único servidor hospedeiro;
- (b) Pocessamento com 2 tarefas simulando 2 unidades CSDs;
- (d) Processamento com 4 tarefas simulando 4 unidades CSDs;

OBSERVAÇÕES

Os experimentos NÃO levaram em consideração o tempo de transmissão dos dados;

Análise dos Resultados



	TOTAL PROCESSING TIME (s)		
	SEQ	U2	U4
TS1-C	4057.2	2616.2	2403.8
TS1-R	3062.1	3335.7	2736.1
TS1-S	2062.8	1637.7	1396.4

Conclusões

Nossos primeiros experimentos foram realizados em um computador básico com 2 núcleos de processamento e sem unidades CSDs instaladas.

Observamos um ganho em *speedup* de 1,69 na conversão das imagens, 1,20 na reprojeção de imagens, e 1,48 na simplificação das imagens simulando o uso de 4 unidades CSDs.

Nos experimentos observamos um ganho potencial com a separação do processamento entre diferentes unidades CSDs, demonstrando o ganho que pode ser obtido com o uso de unidades de armazenamento com *computation storage*.

Para prosseguir com os estudos, será implementado as consultas similares as apresentadas no artigo “POLARDB Meets Computational Storage: Efficiently Support Analytic Workloads in Cloud-Native Relational Database”.

Dúvidas

